

Máster en Big Data, Data Science & Inteligencia Artificial

Universidad Complutense de Madrid

Minería de Datos y Modelización Predictiva

TAREA FINAL

Análisis de la abstención electoral en municipios españoles

Eloy Celaya López

1. Introducción

1.1. Objetivo del estudio

El objetivo de esta práctica es desarrollar dos modelos predictivos, de regresión lineal y regresión logística, a partir de información demográfica y socioeconómica de los municipios españoles junto con los resultados de las últimas elecciones generales. Para ello se emplea el conjunto de datos `DatosEleccionesEspaña.xlsx`, que recoge variables de naturaleza demográfica, económica y territorial a nivel municipal.

Se ha seleccionado como variable objetivo continua el porcentaje de abstención (`AbstentionPtge`), empleado para construir el modelo de regresión lineal, y como variable objetivo binaria la variable `AbstencionAlta`, que toma el valor 1 cuando dicho porcentaje supera el 30 % y 0 en caso contrario, empleada para el modelo de regresión logística. Esta elección permite estudiar el mismo fenómeno desde dos perspectivas complementarias: cuantificar el nivel de abstención y clasificar los municipios según si presentan o no una abstención elevada.

El proceso seguido comprende, en primer lugar, la depuración y preparación del conjunto de datos, y posteriormente la construcción y evaluación de los modelos mediante métodos clásicos de selección de variables.

1.2. Variables objetivo seleccionadas

AbstentionPtge es una variable cuantitativa continua que recoge el porcentaje de abstención registrado en cada municipio. Su análisis mediante regresión lineal permite identificar qué características demográficas y socioeconómicas municipales se asocian con mayor o menor participación electoral.

AbstencionAlta es una variable dicotómica construida a partir de la anterior: toma el valor 1 si la abstención supera el 30 % y 0 en caso contrario. El modelo de regresión logística estimará la probabilidad de que un municipio pertenezca a este grupo de alta abstención en función de sus características explicativas.

El resto de variables objetivo incluidas en el conjunto de datos original (`Izda_Pct`, `Dcha_Pct`, `Otros_Pct`, `Izquierda`, `Derecha`) se eliminan del conjunto de variables explicativas para evitar problemas de redundancia y fuga de información.

1.3. Descripción general del conjunto de datos

El conjunto de datos contiene 8.117 observaciones correspondientes a municipios españoles. Dispone de 41 variables originales, entre las que se encuentran indicadores de estructura demográfica (distribución por edades, proporción de mujeres, población extranjera), actividad económica (paro por sectores, actividad principal del municipio), características territoriales (superficie, densidad, comunidad autónoma) y variables electorales.

Las variables son de naturaleza mixta: la mayoría son cuantitativas continuas, mientras que `CodigoProvincia`, `CCAA`, `ActividadPpal` y `Densidad` son de naturaleza categórica. Antes de iniciar el análisis es necesario verificar que los tipos asignados en la lectura son correctos y realizar las transformaciones oportunas.

2. Depuración de datos

2.1. Importación de datos y asignación de tipos

Los datos se importan desde el fichero Excel mediante pandas. Tras la lectura se comprueba el tipo asignado automáticamente a cada variable. Las variables `CodigoProvincia`, `CCAA` y `ActividadPpal` son de naturaleza categórica pero son leídas como numéricas u object sin codificación adecuada, por lo que se convierten explícitamente al tipo string. `Densidad` ya se lee como object y se gestiona en el apartado de corrección de errores. El resto de variables reciben correctamente el tipo numérico.

A continuación se muestran las variables con tipo de datos erróneo:

<code>CodigoProvincia</code>	<code>int64</code>
<code>CCAA</code>	<code>object</code>
<code>ActividadPpal</code>	<code>object</code>

Mediante el siguiente código se transforman a categóricas:

```
numericasAcategoricas = ['CodigoProvincia', 'CCAA', 'ActividadPpal']
for var in numericasAcategoricas:
    datos[var] = datos[var].astype(str)
```

2.2. Análisis descriptivo inicial

Se realiza un análisis exploratorio previo a cualquier corrección, con el fin de detectar errores en los datos. Para las variables numéricas se calculan los principales estadísticos descriptivos: media, desviación típica, mínimo, máximo, percentiles, asimetría, curtosis y rango.

Del análisis de los estadísticos descriptivos se detectan varios problemas. `Explotaciones` presenta un máximo de 99.999, valor claramente artificial utilizado como código de missing no declarado (189 observaciones). `Age_over65_pct` tiene un mínimo de -18,05 y `ForeignersPtge` de -8,96, valores imposibles para porcentajes. `SameComAutonPtge` alcanza un máximo de 127,16, también fuera del rango [0, 100]. `PobChange_pct`, en cambio, presenta valores entre -52,27 y 138,46 que son perfectamente legítimos al tratarse de una variación de población. Las variables `totalEmpresas`, `Construccion`, `Servicios` e `inmuebles` presentan asimetrías muy elevadas (>40), lo que es esperable en conteos absolutos a nivel municipal.

Para las variables categóricas se obtienen las frecuencias absolutas y relativas de cada categoría mediante la función `analizar_variables_categoricas`. Adicionalmente, se cuenta el número de valores distintos en las variables numéricas para identificar posibles variables mal asignadas como continuas.

Del recuento de valores distintos se confirma que `AbstencionAlta`, `Izquierda` y `Derecha` toman únicamente 2 valores, validando su naturaleza binaria. `PersonasInmueble` presenta solo 282 valores distintos con rango [0,1–3,33], indicando una ratio con poca variabilidad.

Del análisis de frecuencias de las variables categóricas destacan los siguientes puntos. `CCAA` tiene 17 categorías con distribución muy desigual: Castilla y León concentra el 27,7 % de los municipios, mientras que Murcia apenas el 0,6 %. `ActividadPpal` presenta las categorías

Construccion (14 obs., 0,17 %) e Industria (13 obs., 0,16 %) con representación prácticamente nula. Densidad contiene la categoría "?" en 92 municipios (1,13 %).

Del análisis descriptivo se identifican los siguientes problemas a corregir:

- Explotaciones contiene el valor 99999 como código de missing no declarado (189 observaciones).
- TotalCensus, totalEmpresas, Industria, inmuebles y Pob2010 contienen el valor 999 como código de missing no declarado.
- Age_over65_pct, ForeignersPtge, Age_19_65_pct y SameComAutonPtge presentan valores fuera del rango posible [0, 100] para un porcentaje.
- Densidad contiene la categoría "?" para indicar dato desconocido.
- ActividadPpal presenta las categorías Construccion (14 observaciones) e Industria (13 observaciones) con representación insuficiente.

2.3. Corrección de errores detectados

A continuación se detallan las correcciones aplicadas sobre los errores identificados en el análisis descriptivo.

Los valores 99999 de Explotaciones y 999 de TotalCensus, totalEmpresas, Industria, inmuebles y Pob2010 se sustituyen por valores perdidos, ya que se trata de códigos artificiales utilizados para indicar ausencia de dato, como es habitual en ficheros administrativos.

En Age_over65_pct, ForeignersPtge, Age_19_65_pct y SameComAutonPtge se pasan a missing los valores fuera del intervalo [0, 100], por ser imposibles para una variable de tipo porcentaje. Nótese que PobChange_pct, que también puede presentar valores fuera de ese rango, no se filtra: al tratarse de una variación de población puede ser legítimamente negativa o superior al 100 %.

Densidad contiene la categoría "?" para indicar que el dato no está disponible. En lugar de tratarla como un missing convencional, se recategoriza como "Desconocido", siguiendo el mismo criterio aplicado en los ejemplos de clase con la variable Clasificacion: cuando la ausencia de dato es en sí misma informativa, se mantiene como una categoría propia en lugar de imputarse.

ActividadPpal presenta las categorías Construccion (14 obs.) e Industria (13 obs.) con una representación muy reducida. Con una partición 80/20, existe una alta probabilidad de que alguna de estas categorías no aparezca en el conjunto de test, lo que provocaría un desajuste en las columnas generadas por get_dummies entre train y test. Para evitarlo, ambas categorías se reagrupan en "Otro", que ya existía en el conjunto de datos.

A continuación se muestra el código completo utilizado para cada una de estas correcciones:

```
# Missings no declarados en variables numéricas
datos['Explotaciones'] = datos['Explotaciones'].replace(99999, np.nan)

# Valor 999 como código de missing no declarado
for var in ['TotalCensus', 'totalEmpresas', 'Industria', 'inmuebles',
            'Pob2010']:
    datos[var] = datos[var].replace(999, np.nan)

# Valores fuera de rango en porcentajes que deben estar en [0, 100]
porcentajes_rango = ['Age_over65_pct', 'ForeignersPtge', 'Age_19_65_pct',
                     'SameComAutonPtge']

for var in porcentajes_rango:
    datos.loc[~datos[var].between(0, 100), var] = np.nan

# Densidad: '?' es dato no declarado → se trata como categoría
'Desconocido'
datos['Densidad'] = datos['Densidad'].replace('?', 'Desconocido')

# ActividadPpal: Construcción (14 obs) e Industria (13 obs) poco
representadas
# → se reagrupan en 'Otro' para evitar columnas ausentes en test al hacer
get_dummies
datos['ActividadPpal'] = datos['ActividadPpal'].replace({'Construccion':
                                                         'Otro', 'Industria': 'Otro'})
```

A continuación se muestra el output tras la corrección de las categorías de la variable ActividadPpal:

```
Otro          4959
ComercTTEHosteleria  2538
Servicios      620
Name: ActividadPpal, dtype: int64
```

2.4. Análisis de valores atípicos

La detección de valores atípicos se realiza sobre las variables numéricas del conjunto de datos input mediante la función `atipicosAmissing`, que combina criterios basados en la desviación típica y el rango intercuartílico. Los valores identificados como atípicos se sustituyen por missing con el siguiente código, de modo que su tratamiento quede unificado con el resto de valores perdidos en el apartado siguiente:

```
for x in numericas_input:
    datos_input[x] = atipicosAmissing(datos_input[x])[0]
```


Las variables con atípicos detectados son: Population (9,9 %), SameComAutonDiffProvPtge (2,0 %), AgricultureUnemploymentPtge (2,0 %), ConstructionUnemploymentPtge (0,7 %), IndustryUnemploymentPtge (0,6 %), DifComAutonPtge (0,5 %), UnemployLess25_Ptge (0,3 %), Age_19_65_pct (0,3 %) y WomanPopulationPtge (0,3 %). El resto de variables numéricas no presentan valores atípicos según el criterio aplicado.

Population	0.099051
SameComAutonDiffProvPtge	0.020328
AgricultureUnemploymentPtge	0.019958
ConstructionUnemploymentPtge	0.006530
IndustryUnemploymentPtge	0.005914
DifComAutonPtge	0.004928
UnemployLess25_Ptge	0.003203
Age_19_65_pct	0.002834
WomanPopulationPtge	0.002587

La variable con mayor proporción de atípicos es Population (9,9 %), lo que refleja la alta heterogeneidad entre municipios españoles: grandes ciudades como Madrid o Barcelona presentan poblaciones muy alejadas de la distribución típica. En el resto de variables las proporciones son reducidas. En todos los casos se opta por sustituir los atípicos por valores perdidos para su posterior imputación, evitando que distorsionen el ajuste de los modelos.

2.5. Tratamiento de valores perdidos

Se analiza el patrón de missings mediante la función `patron_perdidos`, que muestra la correlación entre las variables con valores ausentes y permite detectar si la pérdida de datos sigue algún patrón sistemático:



El análisis del patrón de missings revela que los valores ausentes no son completamente aleatorios. Se identifican dos grupos de variables con missings correlacionados. El primero agrupa variables de actividad económica: Industria-Construccion (0.82), Construccion-ComercTTEHosteleria (0.68) y totalEmpresas-ComercTTEHosteleria (0.68). El segundo agrupa variables de tamaño y dinámica poblacional: Pob2010-PobChange_pct (0.88), totalEmpresas-PobChange_pct (0.77) y totalEmpresas-Pob2010 (0.68). Adicionalmente, inmuebles y PersonasInmueble presentan correlación perfecta (1.00), lo que es esperable dado que PersonasInmueble es un ratio calculado a partir de inmuebles. Estos patrones sugieren que los missings se concentran en municipios de menor tamaño con menor disponibilidad de registros administrativos.

A continuación se calcula la proporción de missings por variable y por observación. Las variables con más del 50 % de valores perdidos se eliminan del conjunto de datos, y las observaciones con más del 50 % de missings también se descartan.

Ninguna variable supera el umbral del 50 % de valores perdidos, por lo que no se elimina ninguna variable del conjunto de datos. Las variables con mayor proporción de missings son Population (9,9 %) y ForeignersPtge (8,0 %), seguidas de Explotaciones e Industria (2,3 % cada una). En el resto de variables la proporción es inferior al 2,1 %. Cabe destacar que los missings de Population provienen principalmente de los atípicos detectados y convertidos en el paso anterior.

```
# Elimino observaciones con más del 50 % de missings
eliminar = datos_input['prop_missings'] > 0.5
print('Observaciones eliminadas:', int(eliminar.sum()))

datos_input = datos_input[~eliminar]
varObjBin = varObjBin[~eliminar]
varObjCont = varObjCont[~eliminar]
```

✓ 0.0s

Observaciones eliminadas: 0

No se elimina ninguna observación por superar el 50 % de missings. El máximo de prop_missings observado es 0,333, con solo 10 municipios por encima de 0,10 y una mediana de 0. Se confirma así que la gran mayoría de municipios presenta datos completos o con muy pocos ausentes.

Se crea la variable prop_missings para recoger la información sobre la cantidad de missings por observación. La distribución presenta 8 valores distintos, con media 0,011, mediana 0 y máximo 0,333. El 75 % de los municipios tiene prop_missings = 0 y solo 10 observaciones superan el 0,10. Una discretización en intervalos finos generaría categorías con muy pocas observaciones que con alta probabilidad no aparecerían en el conjunto de test, provocando desajustes en las columnas al hacer get_dummies. Por este motivo se opta por una variable binaria: valor "0" para observaciones sin ningún missing (5.841 municipios, 71,9 %) y "con_missings" en caso contrario (2.276 municipios, 28,1 %).

```
# Variable prop_missings por observación
datos_input['prop_missings'] = datos_input.isna().mean(axis=1)
datos_input['prop_missings'].describe()
✓ 0.0s
```

count	8117.000000
mean	0.010819
std	0.020497
min	0.000000
25%	0.000000
50%	0.000000
75%	0.030303
max	0.333333
Name: prop_missings, dtype: float64	

Finalmente, se imputan las variables numéricas y categóricas mediante imputación aleatoria, método que preserva la distribución original de cada variable y es el utilizado en los ejemplos de clase. Tras la imputación se verifica que no queda ningún valor perdido en el conjunto de datos.

```
# Imputación aleatoria variables numéricas
for x in numericas_input:
    datos_input[x] = ImputacionCuant(datos_input[x], 'aleatorio')

# Imputación aleatoria variables categóricas
for x in categoricas_input:
    datos_input[x] = ImputacionCuali(datos_input[x], 'aleatorio')


# Verifico que no quedan missings
datos_input.isna().sum().sum()
✓ 1.7s
0
```

Tras la imputación se verifica que el número total de valores perdidos en el conjunto de datos es 0, confirmando que el proceso de depuración ha sido completado correctamente.

2.6. Relación de las variables con los objetivos


Antes de construir los modelos se estudia la relación de cada variable explicativa con las dos variables objetivo mediante el coeficiente V de Cramer. Esta medida, basada en el estadístico chi-cuadrado, permite cuantificar la asociación entre cualquier tipo de variable y la objetivo, ya que la función `graficoVcramer` discretiza internamente las variables continuas para el cálculo.

Gráfico Vcramer respecto a AbstentionPtge (var. continua):



Las variables con mayor asociación con AbstencionPtge son CodigoProvincia (0.35), CCAA (0.31), ComercTTEHosteleria (0.30), Servicios (0.30) y Construccion (0.30), todas relacionadas con el territorio y la actividad económica municipal. En el extremo opuesto, DifComAutonPtge y SameComAutonPtge presentan V de Cramer próximo a 0, lo que indica escasa relación con la abstención a nivel individual, aunque SameComAutonPtge sí acaba siendo seleccionada por los modelos de regresión al aportar información conjunta con el resto de variables.

Gráfico Vcramer respecto a AbstencionAlta (var. binaria):



Las variables con mayor asociación con AbstencionAlta son CodigoProvincia (0.54) y CCAA (0.52), seguidas de totalEmpresas, TotalCensus y Pob2010 (~0.29). Respecto a la variable continua, aquí las variables de tamaño poblacional (TotalCensus, Pob2010, totalEmpresas) ganan peso relativo, mientras que las variables de actividad económica sectorial (Construccion, ComercTTEHosteleria) pierden protagonismo. DifComAutonPtge y SUPERFICIE siguen siendo las menos relevantes en ambos casos.

3. Modelo de regresión lineal

3.1. Planteamiento

Se construye un modelo de regresión lineal para predecir el porcentaje de abstención (AbstentionPtge) a partir de las variables explicativas depuradas. De acuerdo con el enunciado, no se construye un modelo manual, no se aplican transformaciones sobre las variables y no se incluyen interacciones. La selección de variables se realiza exclusivamente mediante métodos clásicos.

3.2. Partición train-test

El conjunto de datos depurado se divide en un subconjunto de entrenamiento (80 %) y uno de test (20 %), con semilla random_state = 1234567 para garantizar la reproducibilidad. El conjunto de entrenamiento se utiliza para ajustar los modelos y el de test para evaluar su capacidad de generalización.

```
# Partición train / test (80/20)
x_train, x_test, y_train, y_test = train_test_split(
    |  datos_input, varObjCont, test_size=0.2, random_state=1234567)

print('Train:', x_train.shape, '| Test:', x_test.shape)

var_cont = numericas_input.copy()
var_categ = categoricas_input.copy()
✓ 0.0s

Train: (6493, 34) | Test: (1624, 34)
```

3.3. Selección clásica de variables

Los métodos de selección clásica de variables construyen el modelo de forma iterativa, añadiendo o eliminando variables según un criterio de información. En este caso se emplean tres métodos (forward, backward y stepwise) combinados con dos criterios de penalización de la complejidad del modelo (AIC y BIC), dando lugar a seis modelos candidatos. Los códigos empleados son los siguientes:

```
modeloForwAIC = lm_forward(y_train, x_train, var_cont, var_categ, [], 'AIC')
modeloForwBIC = lm_forward(y_train, x_train, var_cont, var_categ, [], 'BIC')
modeloBackAIC = lm_backward(y_train, x_train, var_cont, var_categ, [], 'AIC')
modeloBackBIC = lm_backward(y_train, x_train, var_cont, var_categ, [], 'BIC')
modeloStepAIC = lm_stepwise(y_train, x_train, var_cont, var_categ, [], 'AIC')
modeloStepBIC = lm_stepwise(y_train, x_train, var_cont, var_categ, [], 'BIC')
```

El criterio AIC penaliza cada parámetro adicional con un factor de 2, mientras que BIC aplica una penalización más severa proporcional al logaritmo del tamaño muestral. En consecuencia, los modelos seleccionados por BIC tienden a ser más parsimoniosos, lo que puede resultar en mejor generalización cuando el número de variables es elevado en relación al tamaño muestral.


Forward comienza con un modelo vacío e incorpora en cada paso la variable que más mejora el criterio. Backward parte del modelo completo y elimina la variable que menos deteriora el ajuste. Stepwise combina ambas direcciones, permitiendo añadir y eliminar variables en cada iteración.

Método	R ² Train	R ² Test	Nº Parámetros
Forward AIC	0.4283	0.4181	70
Forward BIC	0.4250	0.4119	61
Backward AIC	0.4321	0.4180	75
Backward BIC	0.4275	0.4089	64
Stepwise AIC	0.4283	0.4181	70
Stepwise BIC	0.4250	0.4119	61

Los resultados muestran un patrón claro: Forward AIC y Stepwise AIC convergen exactamente a la misma solución (R^2 train = 0.4283, 70 parámetros), al igual que Forward BIC y Stepwise BIC (R^2 train = 0.4250, 61 parámetros). Esto indica que, con este conjunto de datos, el stepwise no encuentra mejoras eliminando variables una vez completado el forward. Como era de esperar, los modelos AIC son más complejos que los BIC, incorporando más variables a cambio de una ligera mejora en el ajuste. El Backward AIC es el peor modelo: mayor número de parámetros (75), peor media en validación cruzada (0.400) y mayor variabilidad (std = 0.037), lo que sugiere inestabilidad.

3.4. Selección del modelo ganador

Para seleccionar el modelo ganador se realiza una validación cruzada repetida con 5 folds y 20 repeticiones sobre el conjunto de entrenamiento. Este procedimiento proporciona una estimación más robusta del error de generalización que la simple evaluación sobre el conjunto de test, al reducir la varianza asociada a una única partición.



Método	R ² Train	R ² Test	Nº Parámetros	Media VC	Std VC
Forward AIC	0.4283	0.4181	70	0.412	0.029
Forward BIC	0.4250	0.4119	61	0.409	0.028
Backward AIC	0.4321	0.4180	75	0.400	0.037
Backward BIC	0.4275	0.4089	64	0.412	0.030
Stepwise AIC	0.4283	0.4181	70	0.412	0.029
Stepwise BIC	0.4250	0.4119	61	0.409	0.028

Se selecciona como modelo ganador el obtenido por Forward BIC / Stepwise BIC (modelos 2 y 6, idénticos), con 61 parámetros. Aunque los modelos AIC alcanzan un R² medio en validación cruzada de 0.412 frente a 0.409 de los modelos BIC, la diferencia es de apenas 0.003 puntos — prácticamente irrelevante en términos predictivos. A cambio, los modelos BIC son más parsimoniosos (61 vs 70 parámetros) y presentan la menor variabilidad de todos (std = 0.028). Ante modelos con capacidad predictiva equivalente, se selecciona el más parsimonioso por ser más interpretable, más robusto frente a nuevos datos y más coherente con el criterio BIC utilizado en su construcción. El Backward AIC queda descartado por su mayor inestabilidad (std = 0.037) y peor media (0.400) pese a tener más parámetros.

```
# Modelo ganador lineal
ModeloGanadorLM = modeloStepBIC

ModeloGanadorLM['Modelo'].summary()
```

✓ 0.0s

OLS Regression Results			
Dep. Variable:	AbstentionPtge	R-squared:	0.425
Model:	OLS	Adj. R-squared:	0.420
Method:	Least Squares	F-statistic:	78.06
Date:	Wed, 27 May 2026	Prob (F-statistic):	0.00
Time:	00:20:40	Log-Likelihood:	-20487.
No. Observations:	6493	AIC:	4.110e+04
Df Residuals:	6431	BIC:	4.152e+04
Df Model:	61		
Covariance Type:	nonrobust		

El modelo ganador presenta un R² de 0.425 y un R² ajustado de 0.420, con un F-statistic de 78.06 ($p = 0.000$), confirmando la significación global del modelo. Está compuesto por 61 grados de libertad sobre 6.493 observaciones de entrenamiento. Cabe destacar el aviso de número de condición elevado ($9.44e+05$), indicativo de posible multicolinealidad, esperable dado el elevado número de dummies generadas por CódigoProvincia.

	coef	std err	t	P> t	[0.025	0.975]
const	42.2990	1.772	23.871	0.000	38.825	45.773
SameComAutonPtge	-0.0961	0.008	-12.330	0.000	-0.111	-0.081
Explotaciones	0.0024	0.000	6.165	0.000	0.002	0.003
ConstructionUnemploymentPtge	0.0378	0.007	5.496	0.000	0.024	0.051
ServicesUnemploymentPtge	0.0190	0.003	5.691	0.000	0.012	0.026
IndustryUnemploymentPtge	0.0344	0.007	4.595	0.000	0.020	0.049
Age_19_65_pct	-0.0602	0.013	-4.527	0.000	-0.086	-0.034
Age_0-4_Ptge	0.1927	0.051	3.802	0.000	0.093	0.292
AgricultureUnemploymentPtge	0.0308	0.009	3.487	0.000	0.013	0.048
WomanPopulationPtge	-0.0681	0.021	-3.200	0.001	-0.110	-0.026
SUPERFICIE	2.71e-05	8.77e-06	3.089	0.002	9.9e-06	4.43e-05
CodigoProvincia_10	-2.9958	0.969	-3.091	0.002	-4.896	-1.096

La práctica totalidad de los coeficientes asociados a CodigoProvincia son estadísticamente significativos ($p < 0.05$), así como SameComAutonPtge, Explotaciones, los tres indicadores de desempleo sectorial, Age_19_65_pct, Age_0-4_Ptge, AgricultureUnemploymentPtge y SUPERFICIE. La variable ActividadPpal_Otro es significativa ($p = 0.000$) mientras que ActividadPpal_Servicios lo es al 5% ($p = 0.017$).

3.5. Interpretación de coeficientes


Variable continua — SameComAutonPtge (coef = -0.096): por cada punto porcentual adicional de población residente en el mismo municipio de nacimiento, el porcentaje de abstención disminuye 0.096 puntos porcentuales, manteniendo el resto de variables constantes. Este efecto, aunque pequeño en magnitud unitaria, es altamente significativo y refleja que los municipios con mayor arraigo territorial presentan mayor participación electoral.

Variable categórica — ActividadPpal_Otro (coef = -2.108): los municipios cuya actividad principal se clasifica como "Otro" presentan un porcentaje de abstención 2.11 puntos inferior al grupo de referencia (municipios con actividad principal de comercio, transporte y hostelería), manteniendo el resto de variables constantes.

3.6. Evaluación final del modelo

Se evalúa la robustez del modelo ganador comparando el ajuste en entrenamiento y en test. Una diferencia reducida entre ambos indica que el modelo generaliza bien y no presenta sobreajuste.

El modelo ganador obtiene un R^2 de 0.425 en entrenamiento y de 0.412 en test, con una diferencia de 0.013 puntos — margen reducido que indica que el modelo generaliza correctamente sin sobreajuste relevante.



El gráfico de importancia de variables confirma el dominio absoluto de `CodigoProvincia`, que aporta por sí sola el 27.4% del R^2 total. A gran distancia le siguen `SameComAutonPtge` (1.3%) y `ActividadPpal` (0.84%). El resto de variables contribuyen individualmente con menos del 0.28% cada una, aunque su contribución conjunta es significativa. Este patrón sugiere que la abstención está determinada principalmente por el territorio (provincia) y secundariamente por características socioeconómicas del municipio.

Para aumentar la capacidad predictiva del modelo, habría varias líneas de mejora a explorar. La más directa sería aplicar transformaciones sobre las variables continuas: variables como `Population`, `totalEmpresas` o `Explotaciones` presentan distribuciones muy asimétricas y su relación con `AbstentionPtge` probablemente no es lineal, por lo que una transformación logarítmica podría mejorar el ajuste sin cambiar la estructura del modelo. En la misma línea, algunas variables podrían aportar información tanto en su forma original como transformada, manteniéndose ambas en el modelo. Otra opción sería incorporar interacciones, por ejemplo entre `ActividadPpal` y los indicadores de desempleo sectorial, para capturar que el efecto del desempleo sobre la abstención puede variar según el tipo de municipio. También tendría sentido explorar una agrupación de categorías de `CodigoProvincia` según su nivel medio de abstención, lo que reduciría el número de parámetros y aliviaría la multicolinealidad que apunta el número de condición elevado. Por último, técnicas de regularización como Ridge o Lasso serían una alternativa natural para gestionar esa multicolinealidad estructural derivada de las 49 dummies provinciales.

4. Modelo de regresión logística

4.1. Planteamiento

Se construye un modelo de regresión logística para predecir la probabilidad de que un municipio presente una abstención superior al 30 % (AbstencionAlta). El procedimiento es análogo al descrito en el apartado de regresión lineal: se aplican los mismos métodos de selección clásica de variables sin transformaciones ni interacciones, y la evaluación se realiza mediante los mismos criterios de comparación y validación cruzada.

La principal diferencia respecto a la regresión lineal es que la variable objetivo es binaria, por lo que la métrica de ajuste pasa del coeficiente de determinación R^2 al pseudo- R^2 de McFadden, y la comparación entre modelos candidatos se complementa con el Área Bajo la Curva ROC (AUC), que mide la capacidad discriminante del modelo con independencia del punto de corte elegido.

4.2. Partición train-test

```
# Partición train / test estratificada
x_train_glm, x_test_glm, y_train_glm, y_test_glm = train_test_split(
    datos_input, varObjBin, test_size=0.2, random_state=1234567, stratify=varObjBin)

y_train_glm = y_train_glm.astype(int)
y_test_glm = y_test_glm.astype(int)

print('Train:', x_train_glm.shape, ' | Test:', x_test_glm.shape)
```

✓ 0.0s

Train: (6493, 34) | Test: (1624, 34)

La partición se realiza con los mismos parámetros que en regresión lineal (80/20, random_state = 1234567), añadiendo estratificación por la variable objetivo para garantizar que la proporción de municipios con AbstencionAlta = 1 sea similar en train y en test, especialmente relevante si las clases están desequilibradas.

```
# Reparto de la variable binaria
pd.DataFrame([
    'n': varObjBin.value_counts(),
    '%': varObjBin.value_counts(normalize=True)])
```

✓ 0.0s

	n	%
0	5591	0.688801
1	2526	0.311199

La variable AbstencionAlta presenta un reparto de 5.591 municipios con AbstencionAlta = 0 (68,9 %) y 2.526 con AbstencionAlta = 1 (31,1 %). Las clases están suficientemente equilibradas para no requerir técnicas de rebalanceo, aunque la estratificación en el split garantiza que esta proporción se mantiene en train y test.

4.3. Selección clásica de variables


Se aplican los mismos seis métodos de selección (forward AIC, forward BIC, backward AIC, backward BIC, stepwise AIC, stepwise BIC) que en regresión lineal, con un código muy similar pero utilizando las funciones glm y los datos correspondientes. En este caso la función de coste sobre la que se optimiza es la verosimilitud del modelo logístico, y el criterio AIC/BIC penaliza de la misma forma que en el caso lineal.

Método	pR^2 Train	pR^2 Test	AUC Test	Nº Parámetros
Forward AIC	0.3000	0.2756	0.8348	78
Forward BIC	0.3000	0.2756	0.8348	78
Backward AIC	0.3008	0.2448	0.8332	76
Backward BIC	0.3008	0.2448	0.8332	76
Stepwise AIC	0.2995	0.2754	0.8344	77
Stepwise BIC	0.2995	0.2754	0.8344	77

A diferencia de la regresión lineal, en logística AIC y BIC convergen al mismo modelo para cada método de selección: ForwAIC = ForwBIC y BackAIC = BackBIC. El AUC medio en validación cruzada es prácticamente idéntico para los seis modelos (~ 0.836), pero la diferencia entre pR^2 train y test revela diferencias importantes en robustez: los modelos Backward presentan una brecha de 0.056 puntos (0.3008 vs 0.2448), frente a 0.024 de los modelos Forward, lo que indica sobreajuste más pronunciado en Backward a pesar de tener menos parámetros.

4.4. Selección del modelo ganador

Al igual que en regresión lineal, la selección del modelo ganador se basa en validación cruzada repetida con 5 folds y 20 repeticiones. En este caso la métrica de referencia es el AUC, que es más adecuada para clasificación binaria al no depender de un punto de corte concreto.



Método	pR ² Train	pR ² Test	AUC Test	Media VC	Std VC	Nº Parámetros
Forward AIC	0.3000	0.2756	0.8348	0.836	0.0059	78
Forward BIC	0.3000	0.2756	0.8348	0.836	0.0059	78
Backward AIC	0.3008	0.2448	0.8332	0.836	0.0045	76
Backward BIC	0.3008	0.2448	0.8332	0.836	0.0045	76
Stepwise AIC	0.2995	0.2754	0.8344	0.836	0.0061	77
Stepwise BIC	0.2995	0.2754	0.8344	0.836	0.0061	77

Se selecciona como modelo ganador el Forward AIC / Forward BIC (modelos 1 y 2, idénticos). Aunque el AUC medio en validación cruzada es similar entre todos los modelos, el criterio determinante es la robustez: los modelos Forward presentan la menor diferencia entre pR² train y test (0.024), frente a 0.056 de los modelos Backward. Un modelo con mayor sobreajuste es menos fiable para clasificar nuevos municipios. Entre Forward y Stepwise, Forward obtiene AUC marginalmente superior (0.8348 vs 0.8344) con 1 parámetro menos y mejor estabilidad en validación cruzada (std = 0.0059 vs 0.0061).

Dado que el modelo ganador incluye simultáneamente `CodigoProvincia` y `CCAA`, la multicolinealidad perfecta entre ambas variables hace singular la matriz de covarianza e impide el cálculo de los errores estándar con `summary_glm`. Para mostrar la significación de los parámetros se reajusta el modelo sin `CCAA`, variable que queda implícitamente recogida por las dummies de provincia. Las métricas del modelo ganador no se ven afectadas por esta decisión.

```

resultado = summary_glm(ModeloGanadorGLM_sum['Modelo'], y_train_glm, ModeloGanadorGLM_sum['X'])
print(resultado['Contrastes'].to_string())
print(resultado['BondadAjuste'])

```

✓ 0.6s

	Variable	Estimate	Std. Error	z value	p value	signif
0	(Intercept)	5.938436	0.851770	6.971876	0.000000	***
1	SameComAutonPtge	-0.029781	0.003561	-8.362254	0.000000	***
2	Explotaciones	0.000761	0.000183	4.167766	0.000031	***
3	Age_19_65_pct	-0.029909	0.006530	-4.580122	0.000005	***
4	WomanPopulationPtge	-0.038623	0.009938	-3.886266	0.000103	***
5	SUPERFICIE	0.000008	0.000004	2.164420	0.030469	*
6	PobChange_pct	-0.007695	0.003927	-1.959410	0.050108	.
7	ConstructionUnemploymentPtge	0.007219	0.003070	2.351092	0.018748	*
8	Population	0.000044	0.000023	1.900389	0.057427	.
9	CodigoProvincia_10	-0.464215	0.405127	-1.145850	0.251900	

```

[64 rows x 6 columns],
'BondadAjuste':          LLK          AIC          BIC
0 -2824.097172  5652.194344  5665.751304}



```

La mayoría de los coeficientes asociados a `CodigoProvincia` son estadísticamente significativos ($p < 0.05$), así como `SameComAutonPtge`, `Explotaciones`, los tres indicadores de desempleo sectorial, `Age_19_65_pct`, `Age_0-4_Ptge`, `AgricultureUnemploymentPtge` y `SUPERFICIE`. La variable `ActividadPpal_Otro` es significativa ($p = 0.000$) mientras que `ActividadPpal_Servicios` lo es al 5% ($p = 0.017$).

4.5. Determinación del punto de corte óptimo

El modelo logístico devuelve una probabilidad estimada para cada municipio. Para clasificarlo como AbstencionAlta = 1 o = 0 es necesario fijar un umbral o punto de corte. Se evalúan todos los puntos de corte entre 0 y 1 con paso 0.01 y se comparan dos criterios de selección:

- Maximizar el índice de Youden (Sensibilidad + Especificidad - 1), que equilibra la detección de positivos y negativos.
- Maximizar la Accuracy, que maximiza el porcentaje global de clasificaciones correctas.



```
# Métricas para ambos puntos de corte
sensEspCorte(ModeloGanadorGLM['Modelo'], x_test_glm, y_test_glm,
              pto_youden,
              ModeloGanadorGLM['Variables']['cont'],
              ModeloGanadorGLM['Variables']['categ'],
              ModeloGanadorGLM['Variables']['inter'])
```

✓ 0.0s

PtoCorte	Accuracy	Sensitivity	Specificity	PosPredValue	NegPredValue
0	0.3	0.778941	0.708911	0.62807	0.860531

```
sensEspCorte(ModeloGanadorGLM['Modelo'], x_test_glm, y_test_glm,
              pto_accuracy,
              ModeloGanadorGLM['Variables']['cont'],
              ModeloGanadorGLM['Variables']['categ'],
              ModeloGanadorGLM['Variables']['inter'])
```

✓ 0.0s

PtoCorte	Accuracy	Sensitivity	Specificity	PosPredValue	NegPredValue
0	0.45	0.796182	0.588119	0.707143	0.827243

Se selecciona el punto de corte 0.30, obtenido por maximización del índice de Youden. El objetivo del estudio es identificar municipios con abstención elevada, lo que hace que los falsos

negativos tengan un coste mayor que los falsos positivos: clasificar incorrectamente un municipio con alta abstención como si tuviera baja es más perjudicial que el error contrario. El índice de Youden equilibra sensibilidad y especificidad sin privilegiar ninguna, lo que lo hace más adecuado en este contexto que la Accuracy, que simplemente minimiza el error global. Con el corte en 0.30 se obtiene una sensibilidad del 70.9%, frente al 58.8% del criterio Accuracy, a cambio de perder algo de especificidad (81.1% vs 89.0%) y PPV (62.8% vs 70.7%), un trade-off razonable dado el objetivo del problema.

4.6. Interpretación de coeficientes

Variable continua — SameComAutonPtge (coef = -0.0298, OR = 0.971): un incremento de un punto porcentual en la población residente en el mismo municipio de nacimiento multiplica las odds de AbstencionAlta = 1 por 0.971, es decir, las reduce un 2.9%, manteniendo el resto de variables constantes. Este efecto refleja que el arraigo territorial se asocia con mayor participación electoral.



Variable categórica — Densidad_MuyBaja (coef = -0.770, OR = 0.463): los municipios de densidad muy baja presentan unas odds de abstención alta un 53.7% menores que los municipios de alta densidad (categoría de referencia), manteniendo el resto de variables constantes. Este resultado sugiere que los municipios rurales de muy baja densidad, pese a sus características demográficas, muestran mayor participación relativa.

4.7. Evaluación final del modelo

Se evalúa la robustez del modelo ganador comparando el pseudo- R^2 y el AUC en train y en test, de forma análoga a la evaluación del modelo lineal.


El modelo ganador obtiene un pseudo- R^2 de McFadden de 0.300 en entrenamiento y de 0.277 en test, con una diferencia de 0.023 puntos — margen reducido que confirma la robustez del modelo. El AUC es de 0.844 en train y 0.835 en test, diferencia de 0.009, lo que indica una capacidad discriminante muy estable entre ambas particiones.

A continuación se muestra el gráfico con el área bajo la Curva ROC en train (izquierda) y en test (derecha)



Pto. Corte	Criterio	Accuracy	Sensitivity	Specificity	PPV	NPV
0.30	Youden	0.779	0.709	0.811	0.628	0.861
0.45	Accuracy	0.796	0.588	0.890	0.707	0.827

La diferencia train-test tanto en pseudo- R^2 como en AUC es mínima, confirmando que el modelo no presenta sobreajuste relevante.



CodigoProvincia aporta el 3.8% del pseudo- R^2 , seguida de SameComAutonPtge (1.0%), ActividadPpal (0.37%) y Densidad (0.36%). El patrón de importancia es consistente con el modelo lineal, reforzando la validez de ambos modelos.

Las vías de mejora son en buena parte las mismas que en el modelo lineal. Las transformaciones de variables numéricas aplicarían directamente al término logit, mejorando la relación entre las explicativas y el log-odds de AbstencionAlta. Las interacciones entre variables categóricas, como ActividadPpal y Densidad, capturarían efectos combinados que la especificación aditiva actual no recoge. Una opción específica de la selección logística sería aplicar selección aleatoria de variables: generando múltiples submuestras del conjunto de entrenamiento, aplicando stepwise sobre cada una y quedándose con los modelos que aparecen con más frecuencia, se obtienen estructuras más estables que con una única pasada sobre todos los datos, algo especialmente útil con un número elevado de candidatas.

5. Conclusiones

El proceso de depuración del conjunto de datos ha requerido corregir varios tipos de errores: valores codificados como missing no declarado (99999 en Explotaciones, 999 en TotalCensus, totalEmpresas, Industria, inmuebles y Pob2010), valores fuera de rango en porcentajes (Age_over65_pct, ForeignersPtge, Age_19_65_pct, SameComAutonPtge) y la categoría "?" en Densidad, tratada como categoría propia al considerarse informativa. Las categorías Construcción e Industria de ActividadPpal se reagruparon en "Otro" por su escasa representación, evitando problemas de desajuste entre train y test. La variable prop_missings se codificó como variable binaria dado que el 99% de los municipios presenta proporción de missings igual a cero, haciendo inviable una discretización en intervalos finos. Ninguna variable ni observación fue eliminada por superar el umbral del 50% de missings.

El modelo de regresión lineal ganador, obtenido mediante selección Forward y Stepwise con criterio BIC, explica el 42.5% de la varianza del porcentaje de abstención ($R^2 = 0.425$ en train, 0.412 en test) con 61 parámetros. La diferencia entre train y test es de 0.012 puntos, lo que indica ausencia de sobreajuste relevante. El modelo incluye CódigoProvincia como variable dominante, que por sí sola aporta el 27.4% del R^2 , confirmando que la abstención tiene un fuerte componente territorial a nivel provincial. Tras la provincia, las variables más relevantes son SameComAutonPtge (arraigo territorial) y ActividadPpal (estructura económica del municipio). Los indicadores de desempleo sectorial, la estructura de edad y la superficie aparecen también en el modelo con contribuciones individuales menores pero conjuntamente significativas. Se eligió el modelo BIC frente al AIC por su mayor parsimonia, con una diferencia de R^2 de apenas 0.003 puntos a cambio de 9 parámetros menos.

El modelo de regresión logística ganador, obtenido mediante selección Forward AIC, clasifica los municipios con abstención superior al 30% con un AUC de 0.835 en test y un pseudo- R^2 de McFadden de 0.277. La diferencia entre train y test es mínima (AUC: 0.008; pseudo- R^2 : 0.023), confirmando la robustez del modelo. Las variables seleccionadas son en gran parte las mismas que en el modelo lineal, con CódigoProvincia dominando la importancia (3.8% del pseudo- R^2), seguida de SameComAutonPtge (1.0%), ActividadPpal y Densidad. El punto de corte óptimo se fijó en 0.30 según el índice de Youden, priorizando la sensibilidad (70.9%) sobre la especificidad dado el objetivo de identificar municipios con alta abstención. Con este punto de corte el modelo clasifica correctamente el 77.9% de los municipios. El modelo Forward se prefirió frente a los modelos Backward, que presentaban una brecha train-test notablemente mayor (0.056 en pseudo- R^2) a pesar de tener menos parámetros.

Los resultados de ambos modelos apuntan en la misma dirección. El factor más determinante de la abstención electoral en municipios españoles es el componente territorial a nivel provincial: CódigoProvincia domina la importancia en ambos modelos con una diferencia considerable sobre el resto de variables, lo que sugiere que existen dinámicas culturales, históricas o de oferta política con fuerte variación interprovincial que las variables socioeconómicas disponibles no recogen. Después de la provincia, el arraigo territorial medido por SameComAutonPtge es el predictor socioeconómico más consistente: los municipios con mayor proporción de población nacida en el propio municipio presentan menor abstención, en línea con la idea de que la cohesión comunitaria favorece la participación. La estructura económica del municipio, recogida por ActividadPpal, ocupa el tercer lugar. Los indicadores de desempleo sectorial, la estructura de edad y la superficie tienen efectos individuales pequeños pero que se mantienen en ambos modelos, lo que refuerza su relevancia. En conjunto, los modelos sugieren que la abstención en España depende más de dónde está el municipio y de su identidad territorial que de sus características sociodemográficas concretas.